



**ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR**
Membre de **HONORIS UNITED UNIVERSITIES**

Filière : Intelligence artificielle et sciences des données
Module : Architecture de données

Projet Scraping Site web d'actualités pour l'Analyse des Articles de Presse

Réalisée par : El Hattab Maria – Zouhairi Ihssane

Encadré par : Tabii Youness

Année Universitaire : 2025 / 2026

Plan de la Presentation

01

Contexte & Problematique

02

Architecture Globale du Systeme

03

Sources de Donnees & Ingestion

04

Architecture Medallion (Bronze / Silver / Gold)

05

Orchestration & Qualite des Donnees

06

Visualisation & Resultats

Contexte & Problématique

Problématique

- Des milliers d'articles publiés chaque jour sur des sources hétérogènes
- Trois langues : arabe, français, anglais
- Données brutes contenant erreurs et doublons
- Aucun système centralisé d'analyse
- Collecte manuelle impossible à l'échelle

6

Sources

3

Langues

Notre Solution

- Pipeline automatisé de collecte multi-sources
- Architecture Médaille pour la qualité des données
- Ingestion batch + streaming en temps réel
- Data Warehouse avec modèle en étoile
- Dashboards analytiques interactifs


135+

Articles

94.5%

Qualité

Architecture Globale du Systeme



Architecture : Batch (Airflow) + Streaming (Kafka)

Sources de Données & Méthodes d'Ingestion

Hespress

Pays : Maroc

Langue : Arabe

Méthode : Scrapy Spider

National

Akhbarona

Pays : Maroc

Langue : Arabe

Méthode : BeautifulSoup

National

BBC News

Pays : Royaume-Uni

Langue : Anglais

Méthode : BeautifulSoup

International

CNN

Pays : Etats-Unis

Langue : Anglais

Méthode : Flux RSS

International

Al Jazeera

Pays : Qatar

Langue : Anglais

Méthode : Flux RSS

International

Reuters

Pays : Royaume-Uni

Langue : Anglais

Méthode : Flux RSS


Agence

Ingestion Streaming - Apache Kafka




Les articles d'une même source arrivent dans la même partition, dans l'ordre chronologique

Architecture Médaillon - Bronze / Silver / Gold




Data Warehouse - Modèle en Etoile



Orchestration - Apache Airflow

DAG : `press_lakehouse_pipeline` — Schedule : toutes les heures



Configuration du DAG

Schedule	Toutes les heures (cron : 0 * * * *)
Retries	2 tentatives automatiques avec delai de 3 minutes
Timeout	30 minutes maximum par tâche
Executor	SequentialExecutor (SQLite) — environnement dev
Monitoring	Interface web Airflow sur http://localhost:8082

Qualité des Données - Score 94.5%

Complétude

Champs obligatoires
non nuls

- ✓ titre présent
- ✓ URL valide
- ✓ source connue
- ✓ date présente

Validité

Format et
règles métier


- ✓ titre ≥ 5 chars
- ✓ URL commence par http
- ✓ Date parseable
- ✓ Contenu ≥ 50 mots

Cohérence

Consistance
globale

- ✓ Pas de doublons URL
- ✓ Date 2020 $\rightarrow$ 2026
- ✓ Source dans liste

Score qualité par source (%)



Score Moyen

94.5%


154 articles analyses

Seuil acceptable : 70%

Résultats & Visualisation Power BI


Analyse des Articles de Presse — Data Lakehouse

Evolution temporelle de publication des articles




135
Total Articles


Répartition des articles par langue



Nombre d'articles par catégorie



Articles par Source



Résultats & Visualisation Power BI

nom_source	Year	Month	Day	langue_detectee	titre	url
akhbarona	2026	May	7	ar	الأرض تهتز تحت أقدام ساكنة تطوان وضواحيها الساحلية مجددا	https://www.akhbarona.com/society/425455.html
akhbarona	2026	May	7	ar	المنتخب المغربي يواجه مدعشقر وبدأ بالرباط تأهيا لمونديال 2026	https://www.akhbarona.com/sport/lionatlas/425458.html
akhbarona	2026	May	7	ar	انتخابات 23 شتنبر... تفاصيل لقاء وزير الداخلية مع قادة الأحزاب السياسية	https://www.akhbarona.com/politic/425457.html
akhbarona	2026	May	7	ar	إيداع المؤثر "قرعون" بسجن ككافة على خلفية حادثة مطاردة انتهى بوفاته	https://www.akhbarona.com/society/425465.html
akhbarona	2026	May	7	ar	براءة فضل شاكر تديد الجدل إلى الواجهة... وتهنئة الشيخ المغامري له تفتح نقاشا واسما	https://www.akhbarona.com/culture/425456.html
akhbarona	2026	May	7	ar	"يسبب اشتباه في فيروس "هانتا" .. المغرب يرفض هبوط طائرة طبية بمراكش وتحويل مسارها نحو "الكنتاري	https://www.akhbarona.com/society/425440.html
akhbarona	2026	May	7	ar	جوائز تحت الطلب... تجارة جديدة تكتسح الوسط الفني بالمغرب في عوالب نام لأدنى معايير المصداقية والاستحقاق	https://www.akhbarona.com/culture/425435.html
akhbarona	2026	May	7	ar	في أول خروج له.. الملتزم ضحية الـ"كرويساج" بفاس يحكي تفاصيل الواقعة وكيف ألقاه حديث لبوي شريف	https://www.akhbarona.com/society/425467.html
akhbarona	2026	May	7	ar	قربلة في ريال مدريد.. فاليريدي في المستشفى بعد شجار عنيف مع تشواميلي وإدارة الملكي تلان الطوارئ	https://www.akhbarona.com/sport/realmadrid/425460.html
akhbarona	2026	May	7	ar	هل نتجه الصبية لرفع عقوية الويكلي عن الرجاء قبل النبربي؟	https://www.akhbarona.com/sport/footmarocain/425459.html
akhbarona	2026	May	7	fr	Article simulé #1 — akhbarona	https://akhbarona.com/article-1
akhbarona	2026	May	7	fr	Article simulé #4 — akhbarona	https://akhbarona.com/article-4
akhbarona	2026	May	7	fr	Article simulé #5 — akhbarona	https://akhbarona.com/article-5
akhbarona	2026	May	9	ar	الببسطاج و"الكاجو" يشعلان دورة مجلس التقيق (فيديو)"	https://www.akhbarona.com/society/425542.html
akhbarona	2026	May	9	ar	ظوه يخذل... هل يقشن المعارضة حملة مقاطمة للهوم بسبب لهيب الأسعار وتحتول المضاربين؟"	https://www.akhbarona.com/economy/425547.html
akhbarona	2026	May	9	ar	أحد أقارب الفنان عبد الوهاب الكالي يكتف لـ"أخبارنا" السبب المحتمل للوفاة حسب ما يتداول داخل العائلة	https://www.akhbarona.com/culture/425509.html
akhbarona	2026	May	9	ar	استفانر بإسبانيا بسبب سببة ومليلية وتحتيرات من "مفاجأة أمريكية" لصالح المغرب	https://www.akhbarona.com/world/425505.html
akhbarona	2026	May	9	ar	استفانر بأكثير... حريق محدود بالمركز الاستشفائي الجامعي محمد السادس دون مخلفات بشرية أو مادية	https://www.akhbarona.com/society/425545.html
akhbarona	2026	May	9	ar	استفانر صحن في 12 دولة لملاحة ركاب سببة "هانتا" بعد تسجيل وفيات وإصابات	https://www.akhbarona.com/world/425543.html
akhbarona	2026	May	9	ar	إغفاءات جمركية لمغاربة العالم .. سقف 25 ألف درهم وقرب صرامة	https://www.akhbarona.com/economy/425537.html
akhbarona	2026	May	9	ar	الاعتداء على مهاجر إفريقي والنحريض على الكراهية يقود عشرينيا للاعتقال بالدار البيضاء	https://www.akhbarona.com/society/425540.html
akhbarona	2026	May	9	ar	المغرب الفاسي يخرج عن صمته في قضية سفيان بجديدة	https://www.akhbarona.com/sport/footmarocain/425534.html
akhbarona	2026	May	9	ar	اتعلمن مرتقب.. مليلية المحتلة تستعد لعودة "التفريغ الميعيني" عبر المعابر الحدودية	https://www.akhbarona.com/economy/425550.html
akhbarona	2026	May	9	ar	إلغيتيو: لحظة فوز تاريخية ببرلماج أمريكي شهير... والوجهة المغرب	https://www.akhbarona.com/culture/425541.html
akhbarona	2026	May	9	ar	بريطانيا تدين هجمات "البوليساريو" الإرهابية وتدعو للالتزام بجهود السلام في الصحراء المغربية	https://www.akhbarona.com/world/425511.html
akhbarona	2026	May	9	ar	يشري سارة.. "الأمد" أشرف حكيمي سيكون جاهزا لهالي "الشامبيونز ليغ" والمونديال	https://www.akhbarona.com/sport/proplayers/425548.html
akhbarona	2026	May	9	ar	بعد نسخة قمر .. المغربية "أورا تقي" دجمة افتتاح مونديال 2026	https://www.akhbarona.com/sport/worldfoot/425539.html
akhbarona	2026	May	9	ar	ترويتت كهرلابة تنسب في وفاة طفل تحت عجلات شاحنة بتطوان	https://www.akhbarona.com/society/425514.html
akhbarona	2026	May	9	ar	خديجة بن كة تنعى عبد الوهاب الكالي: "مرسول الحب" كان مغربيا وجزائريا في وجدان كل العرب	https://www.akhbarona.com/culture/425512.html

Conclusion

Réalisations

- Pipeline complet de la collecte à la visualisation
- Architecture Médaille Bronze/Silver/Gold opérationnelle
- Kafka Streaming + Batch Airflow fonctionnels
- Score qualité moyen de 94.5% sur 154 articles
- 6 sources, 3 langues, orchestration horaire
- Infrastructure entièrement dockerisée

Merci pour votre attention